

Gabriel Pereira Mendonça Passos
Felipe Kenzo Suguimoto

Trabalho Final de Ciência de Dados

Documento desenvolvido para a disciplina
Ciência de Dados, ministrada pelo professor
Eduardo Pena.

Universidade Tecnológica Federal do Paraná – UTFPR
Câmpus Campo Mourão
Bacharelado em Ciência da Computação

Campo Mourão
Junho / 2026

1 Identificação do Grupo

Alunos:

- Gabriel Pereira Mendonça Passos
- Felipe Kenzo Suguimoto

Repositório Git:

<https://github.com/GabrielMenPassos/TrabalhoFinalCienciaDeDados>

2 Descrição do Dataset

O dataset selecionado para o desenvolvimento do projeto é composto por registros de compras públicas disponibilizados em formato aberto por meio do portal Dados.gov.br.

A base contém informações referentes a processos de aquisição realizados por órgãos públicos brasileiros, incluindo dados sobre fornecedores vencedores, valores contratados, quantidades adquiridas e classificação dos itens comprados.

Entre os principais atributos disponíveis destacam-se:

- descrição resumida do item;
- valor unitário estimado;
- valor unitário homologado;
- quantidade adquirida;
- fornecedor vencedor;
- órgão contratante;
- código da classe;
- código do grupo.

A base possui mais de 10.000 registros e apresenta potencial para integração com informações complementares, além de permitir a criação de novos atributos por meio de técnicas de engenharia de atributos. Essas características tornam o conjunto de dados adequado para tarefas de classificação supervisionada e análise exploratória.

3 Contexto e Justificativa

A transparência dos gastos públicos é um dos principais mecanismos de controle social e fiscalização da administração pública. Nos últimos anos, a disponibilização de bases abertas por órgãos governamentais permitiu ampliar o acesso da população a informações sobre licitações, contratos e aquisições realizadas com recursos públicos.

Apesar dessa disponibilidade, o grande volume de registros dificulta a realização de análises manuais capazes de identificar comportamentos incomuns ou padrões potencialmente suspeitos. Em muitos casos, relações entre fornecedores, órgãos públicos e valores contratados podem passar despercebidas sem o auxílio de técnicas analíticas adequadas.

Nesse contexto, a Ciência de Dados oferece ferramentas capazes de processar grandes volumes de informações, identificar padrões e apoiar processos de auditoria e fiscalização. A utilização de técnicas de análise exploratória e aprendizado de máquina pode contribuir para a identificação de características associadas a contratações potencialmente atípicas, permitindo direcionar investigações mais detalhadas.

Este projeto busca combinar análise exploratória e modelagem preditiva para compreender quais fatores estão mais associados a padrões potencialmente suspeitos em compras públicas e avaliar a capacidade de algoritmos de aprendizado de máquina em identificar esses casos.

4 Perguntas de Pesquisa

1. Quais fatores estão associados a possíveis indícios de irregularidade em compras públicas?
2. É possível identificar compras públicas com maior risco de comportamento suspeito utilizando técnicas de Machine Learning?

5 Hipóteses

H1: Compras realizadas com baixa concorrência apresentam maior risco de comportamento suspeito.

H2: Diferenças pequenas entre o valor estimado e o valor homologado podem indicar baixa competitividade no processo licitatório.

H3: Compras com valores significativamente acima ou abaixo da média de sua categoria apresentam maior probabilidade de serem classificadas como potencialmente suspeitas.